

Анализ перевода авторских номинаций как маркера идиостиля переводчика (на примере романа Дж.Р.Р. Толкина “Властелин Колец”)

Курсы ДПО "Компьютерная лингвистика"

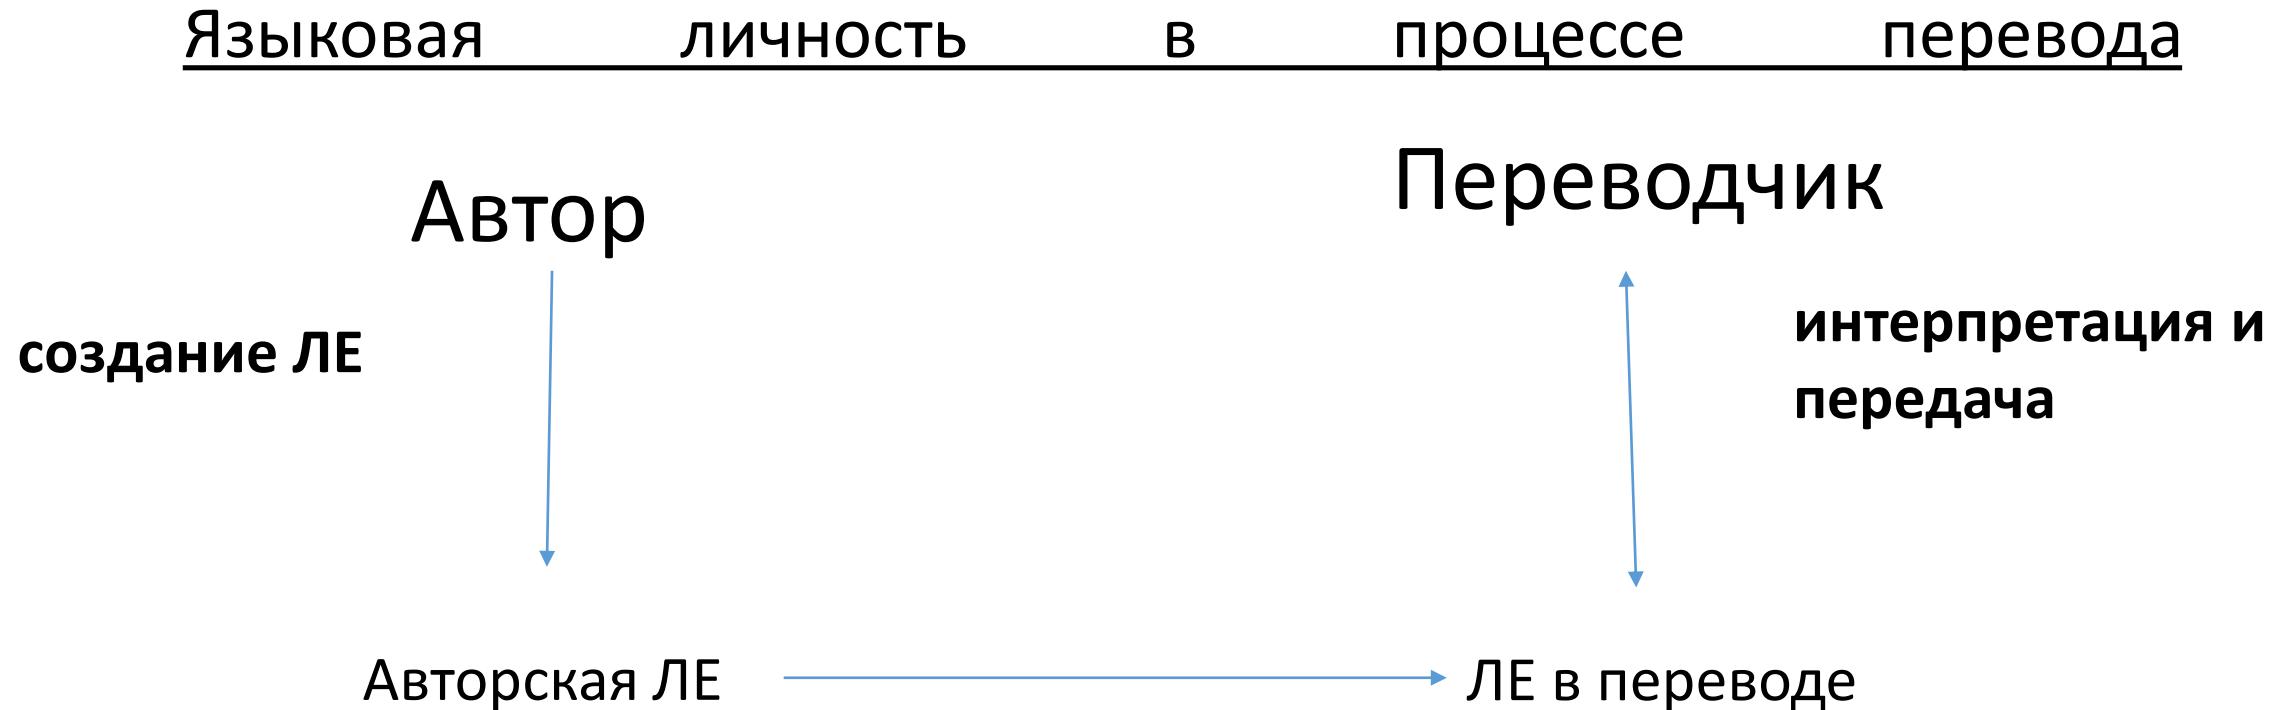
Учебный проект №2

Студеникина Д.

Основные понятия

- *Номинация* — процесс и результат именования, то есть присвоения имени обозначаемому объекту.
- *Идиостиль* — совокупность характерных языковых и текстовых особенностей, которые отличают носителя языка
- *Языковая личность* — это носитель языка, обладающий уникальной совокупностью вербальных, когнитивных и мотивационных характеристик, которая проявляется в создаваемых им речевых произведениях.

Языковая личность переводчика в аспекте перевода авторских номинаций



Гипотеза

Выбор способа перевода авторской лексики является достаточно устойчивым и уникальным для каждого переводчика, чтобы служить основой для автоматической атрибуции перевода

Цель работы

Оценить степень уникальности идиоматики каждого переводчика на основе анализа перевода авторской лексики

Задачи:

- Подготовить корпус параллельных контекстов (оригинал + 3 перевода)
- Обучить модель узнавать переводчика на основе перевода авторских номинаций (на корпусе А)
- Проверить, узнает ли модель переводчика (на корпусе В с другим набором номинаций и на корпусе С с замаскированными номинациями)

Этапы:

- Подготовка корпуса параллельных переводов (оригинал + переводы)
- Аннотировать параллельный корпус
- Разделить на корпусы
- Обучить модель на корпусе А, используя таблицу переводов номинаций
- Проверить способность предсказания переводчика по корпусу В
- Проверить способность предсказания переводчика по корпусу С

Таблица номинаций и их переводов

| | A | B | C | D |
|----|-----------------------|---------------------|-------------------|------------------------|
| 1 | original | 1 | 2 | 3 |
| 2 | Zirak-zigil | Зиракзигил | Зирак Зигиль | Зирак-Зигил |
| 3 | Zirak | Зирак | | Зирак |
| 4 | Yule | Просечень | | Юл |
| 5 | Yellow Face | Желтая Морда | Желтый Лик | Желтое Лицо |
| 6 | Yale, lowlands of the | Йельские Низины | | Йельская низина |
| 7 | Wraith-lord | | | Король Призраков |
| 8 | Wraith-king | | | Король-Призрак |
| 9 | Woses | лешаки | Лесные Люди | Воосы |
| 10 | Wormtongue | Гнилоуст | Червослов | Червеуст |
| 11 | Worm | Гниль | Червяк | Червяк |
| 12 | World's End | | | край мира |
| 13 | Woody End | Лесной Угол | Залесье | Лесной Угол |
| 14 | Woodhall | Лесной Чертог | Задоры | Лесной Приют |
| 15 | Wood-elves | лесные эльфы | | Лесные Эльфы |
| 16 | Wold of Rohan | раздолье Ристании | | Волд, Стена Эмин Муйла |
| 17 | Wold | | | Волд |
| 18 | Wizard's Vale | Колдовская логовина | Колдовская Долина | Чародеева Долина |
| 19 | Withywindle | Ветлянка | Ивлинка | Ивий Вьюн |
| 20 | Withered Tree | | | Увядшее Дерево |

Пример корпуса

| | A english | B russian_1 | C russian_2 | D russian_3 | E nom.orig | F nom.1 | G nom.2 | H nom.3 |
|----|----------------------------------|------------------------------|---|-----------------------------|----------------------------|---------------------|------------|------------|
| 1 | That way lies Aglarond and thi | Вон там тень – это устье Уще | А там – Агларонд и Сверкаю | Свернув туда, мы с тобой мс | Aglarond | Агларонд | Агларонд | Агларонд |
| 2 | And I walk in Ambaróna, in | Остались мне Амбарон, | А со мною остались – | Амбаронэ, Тауреморнэ, | Aldalómë | Аладоломэ | Альдаломэ | Алдаломэ |
| 3 | Then a minstrel and loremaste | И встал менестрель, и подн | Он назвал поименно всех к | Тогда выступил на середину | Aldor | Алдор | Элдор | Алдор |
| 4 | And I walk in Ambaróna, in | Остались мне Амбарон, | А со мною остались – | Амбаронэ, Тауреморнэ, | Ambaróna | Амбарон | Амбарона | Амбаронэ |
| 5 | At length they came to land | В конце концов они | Наконец они высадились у | В конце концов они снова | Amon Lhaw | Наслух | Амон Лав | Амон Лау |
| 6 | But they closed round at | Заверти высилась | А еще раньше, в дни | Но еще задолго | Amon Sûl | Амон-Сул | Амон Сул | Амон Сул |
| 7 | Tirelessly he strode from Cita | Без устали расхаживал он от | Он появлялся и у Цитадели, А Гэндальф без устали шага | Amroth | | | | Амрот |
| 8 | Upon the other hill hard by stc | На другом холме разевали | Он стоял с Гэндальфом на о | На другом холме разевали | Amroth | | | Амрот |
| 9 | And the last king of the line of | У последнего князя в колене | И вот последний король из | Наконец последний король | Anárión | Анарион | Анарион | Анарион |
| 10 | In the stern sat Aragorn son of | Неколебимо и гордо, с подн | Темные волосы разевалиси | Его капюшон был откинут; т | Anárion | | | |
| 11 | It has been said that dragon-fí | Было поверье, что | Магическ | Говорят, Кольца Власти горе | Говорят, Кольца Власти пла | Ançalagon the Black | | |
| 12 | All lands east of the Anduin s | Все земли к востоку от | Итилиен навсегда отх | Весь Итилиен навсегда отх | Anduin | Андуин | | Андуин |
| 13 | And on the third night after an | Я сидел туманной ночью по | На третью ночь после того я | Поздно вечером, в сером по | Anduin | Андуин | | Андуин |
| 14 | And standing there they surve | Далеко внизу видны были | Далеко внизу, как белые сто | Остановившись над пропаст | Anduin | | | Андуин |
| 15 | And the Shadow departed, anc | Тень уползла, открылось | никакой тени не было и в | Тень рассеялась, солнце очи | Anduin | Андуин | Андуин | Андуин |
| 16 | But Anduin is near, and Andui | Но здесь течет | Андуин и кат | Но Андуин близок, и Андуин | Anduin | Андуин | Андуин | Андуин |
| 17 | Far above a great cloud strea | Высоко в небесах ползла на | Вся долина Андуина замерл | Из Черной Страны медленн | Anduin | Андуин | Андуин | Андуин |
| 18 | Far away to the right the Andu | Днем он нервно поблескива | Далеко справа погасли | Далеко справа залегла непр | Anduin | Андуин | Андуин | Андуин |
| 19 | | | | | | | | |

Random Forest

Обучение на корпусе А определять переводчика

Проверка обобщения/запоминания на корпусе В

Проверка на корпусе С – насколько падает узнавание переводчика без номинаций

Корпус А

Обучающая выборка: 3937 примеров

Тестовая выборка: 985 примеров

РАСПРЕДЕЛЕНИЕ В ТЕСТОВОЙ ВЫБОРКЕ:

Переводчик 1: 373 примеров (37.9%)

Переводчик 2: 282 примеров (28.6%)

Переводчик 3: 330 примеров (33.5%)

Корпус А

Точность: 59.09%

(случайное угадывание: 33%)

| | precision | recall | f1-score | support |
|--|-----------|--------|----------|---------|
|--|-----------|--------|----------|---------|

| | | | | |
|--------------|------|------|------|-----|
| Переводчик 1 | 0.51 | 0.99 | 0.67 | 373 |
|--------------|------|------|------|-----|

| | | | | |
|--------------|------|------|------|-----|
| Переводчик 2 | 0.77 | 0.18 | 0.29 | 282 |
|--------------|------|------|------|-----|

| | | | | |
|--------------|------|------|------|-----|
| Переводчик 3 | 0.86 | 0.49 | 0.62 | 330 |
|--------------|------|------|------|-----|

| | | | | |
|----------|--|------|-----|--|
| accuracy | | 0.59 | 985 | |
|----------|--|------|-----|--|

| | | | | |
|-----------|------|------|------|-----|
| macro avg | 0.71 | 0.55 | 0.53 | 985 |
|-----------|------|------|------|-----|

| | | | | |
|--------------|------|------|------|-----|
| weighted avg | 0.70 | 0.59 | 0.55 | 985 |
|--------------|------|------|------|-----|

Корпус А

МАТРИЦА ОШИБОК:

предсказано

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [369 1 3]

Реально 2: [207 51 24]

Реально 3: [154 14 162]

Корпус А

Точность: 58.05%

Большинство фрагментов приписано Переводчику 1

Корпус В

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Переводчик 1 | 0.42 | 0.99 | 0.59 | 506 |
| Переводчик 2 | 0.87 | 0.13 | 0.22 | 506 |
| Переводчик 3 | 0.91 | 0.42 | 0.58 | 506 |
| accuracy | | 0.51 | 1518 | |
| macro avg | 0.73 | 0.51 | 0.46 | 1518 |
| weighted avg | 0.73 | 0.51 | 0.46 | 1518 |

Корпус В

МАТРИЦА ОШИБОК (корпус Б):

предсказано

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [502 0 4]

Реально 2: [425 65 16]

Реально 3: [282 10 214]

СРАВНЕНИЕ С КОРПУСОМ А:

Корпус А (известные имена): 58.05%

Корпус Б (новые имена): **51.45%**

Разница: -6.60%

RF

Корпус В

Точность 51.45%

Много фрагментов приписано Переводчику 1

Модель хорошо обобщает новые имена

Корпус С

Маскировка номинации = [ном]

МАТРИЦА ОШИБОК (корпус С):

предсказано

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [374 0 0]

Реально 2: [374 0 0]

Реально 3:[374 0 0]

Итог

Точность на корпусе С без имен: **33.33%**

(корпус А с именами: 58.05%)

(корпус Б с новыми именами: 52.17%)

Вклад имен: 51.84%

Линейная регрессия

Обучение на корпусе А определять переводчика

Проверка обобщения/запоминания на корпусе В

Проверка на корпусе С – насколько падает узнавание переводчика без номинаций

Корпус А

МАТРИЦА ОШИБОК:
предсказано

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [302 46 25]

Реально 2: [75 183 24]

Реально 3: [64 85 181]

Точность: 67.61%

Корпус В

МАТРИЦА ОШИБОК:

предсказано

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [359 137 10]

Реально 2: [128 357 21]

Реально 3: [68 178 260]

Точность: 64.30% (корпус А: 67.61%)

Разница: -3.32%

Корпус С

МАТРИЦА ОШИБОК:

| 1 | 2 | 3 |
|---|---|---|
|---|---|---|

Реально 1: [9 365 0]

Реально 2: [3 371 0]

Реально 3: [3 371 0]

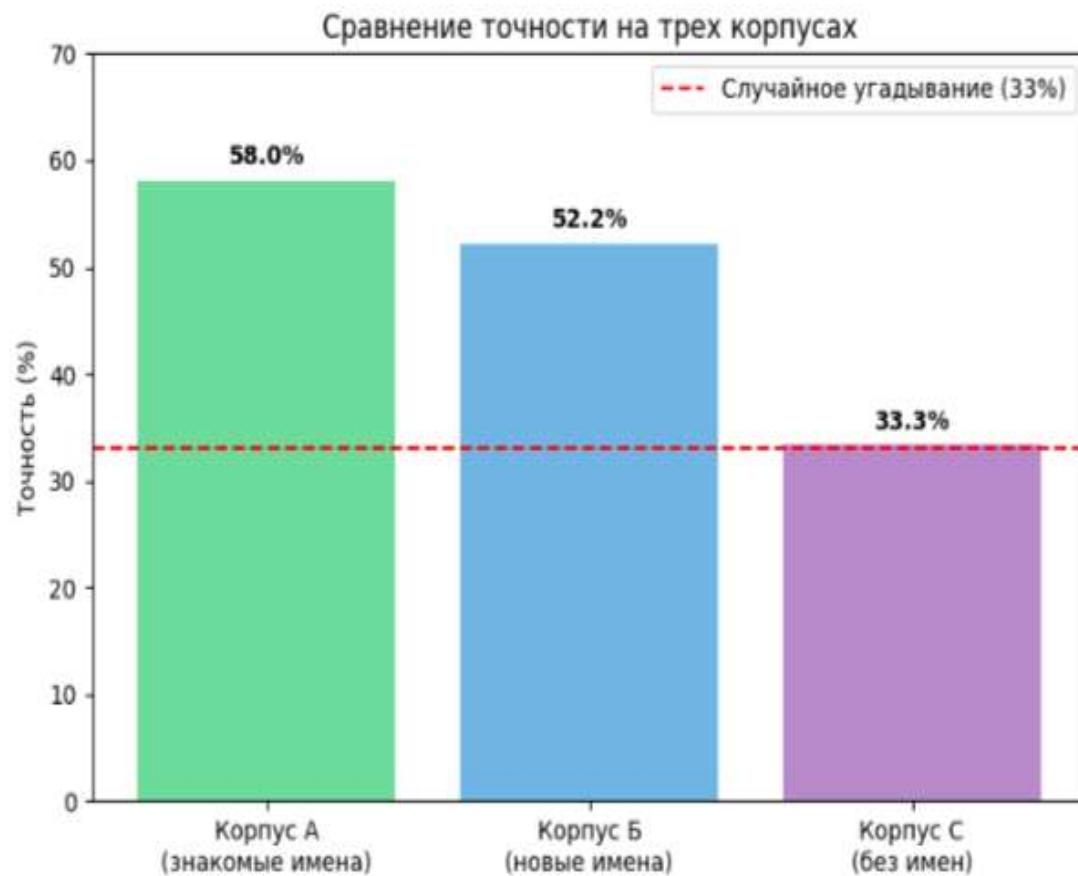
Точность: 33.87%

Итог

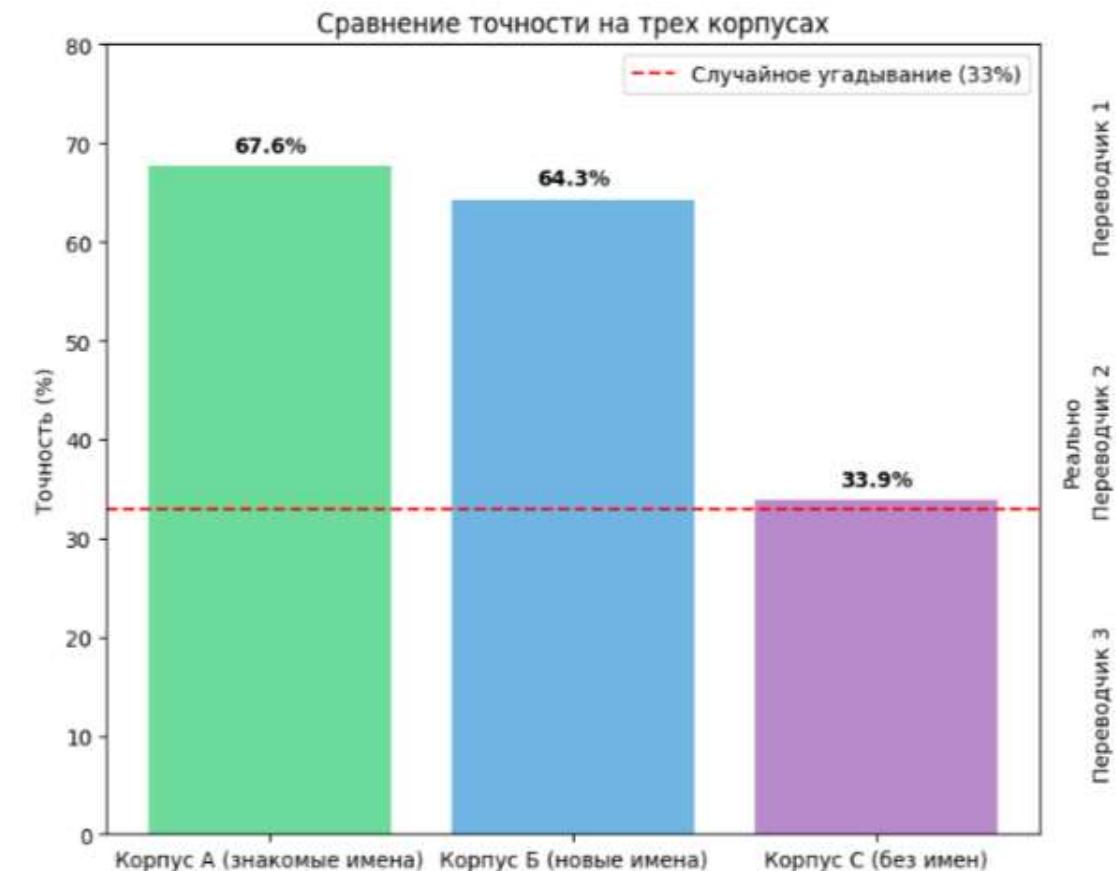
| Корпус | Точность % |
|--------------------|------------|
| А (знакомые имена) | 67.614213 |
| Б (новые имена) | 64.295125 |
| С (без имен) | 33.868093 |

Сравнение Random Forest и Линейной регрессии

Random Forest



Linear Regression



Проблемы исследования

Отсутствует эксперимент по оценке стилистических различий (без фокуса на именах)

Решение:

1. Обучение на стилистических особенностях
2. Обучение на авторских номинациях
3. Сравнение

Сложности при исследовании

Проблемы с формированием корпуса

Проблемы с таблицей номинаций

Особенности авторских номинаций

составные имена + вторичная номинация

Original

1

2

3

accursed Tower

-

Проклятая Башня

Orthanc

Ортханк

Ортханк

(Отрханская крепость)

Орфанд

Проблемы с поиском имен в корпусе

Вторичная номинация

Original

1

2

3

White Face

Белая Морда

Белый Лик

Белое Лицо

“Эовин стояла [...] с белым лицом...”

Проблемы с поиском имен в корпусе

| | | | |
|------|------------|------------|--------|
| king | конунг | повелитель | король |
| king | повелитель | повелитель | король |
| lord | конунг | король | король |

Решение

Сосредоточиться на уникальных номинациях

| | | | |
|---------------------|----------------|----------|-------------------|
| Bag End, Under-Hill | Торба-на-Круче | Засумки | Холм под Котомкой |
| Éowyn | Эовин | Йовин | Эовейн |
| Amon Sûl | Амон-Сул | Амон Сул | Амон Сул |

Разделить номинации на группы
(антропонимы, топонимы, события и др.)

Инструментарий

Библиотеки:

Pandas

NumPy

Scikit-learn

razdel

Sentence Transformers

Matplotlib

Методы:

LinearRegression

Random Forest

Спасибо за внимание

